

Miniproyecto 2 - entrega 2

Nicolás Garnica (201713127)
Universidad de los Andes
pn.garnica@uniandes.edu.co

César Zapata (201730655)
Universidad de los Andes
ca.zapatar@uniandes.edu.co

1. Parte teórica

1.1. Ruidos sal y pimienta.

Los ruidos de sal y pimienta consisten en una dispersión de ruido en que no necesariamente hay muchos píxeles con ruido, pero este ruido es muy marcado (estando en los valores de negro o blanco), y se asemeja a una aspersión con aerosol [2]. En el ruido gaussiano el valor de los píxeles del ruido siguen una distribución gaussiana [1], y el ruido uniforme, al igual que el ruido gaussiano, le debe su nombre a la probabilidad de que los píxeles del ruido presenten cierto valor (en este caso los diferentes valores que pueden tomar tienen una probabilidad uniforme) [3]. La imagen noisy_1 muestra evidencia de un poco de ruido de pimienta, y ruido uniforme, mientras que noisy_2 presenta ruido de pimienta en toda la imagen, pero sin trazos de otro ruido.

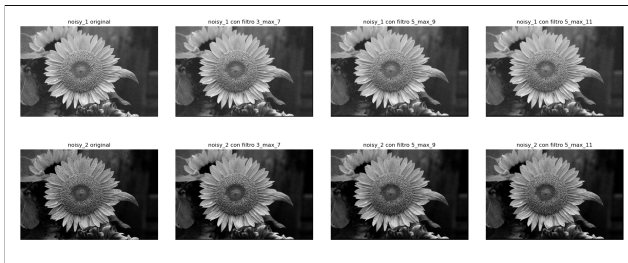


Figure 1. Subplot de las imágenes noisy_daisy_1 y noisy_daisy_2, con sus respectivas imágenes filtradas con tamaños de ventana y máximo de ventana diversos.

1.2. Comparación de tamaños para el filtro de mediana adaptativa.

Como se observa en el subplot, a medida que el tamaño de ventana se hace más grande, se dejan de filtrar los recuadros de ruido más pequeño, y se pierde definición en los bordes de la imagen.

1.3. Filtros Gaussianos para reducir el ruido



Figure 2. Subplot de las imágenes noisy_daisy_1 y noisy_daisy_2, con sus respectivas imágenes filtradas por método de Gauss.

En el subplot se evidencia que las mejores combinaciones de tamaño y sigma para filtrar la imagen por el método de Gauss para ambas imágenes (noisy_1 y noisy_2) fueron tamaño 3 con sigma 11, y tamaño 7 con sigma 2. Donde el primero reduce un poco el ruido, manteniendo bordes y detalles en la imagen, mientras el segundo reduce significativamente el ruido con la consecuencia de que la imagen pierde resolución.

2. Parte biomédica

Dado que el metodo anterior de correlacion no nos funcionaba, nos vimos en la obligacion de tener que modificarlo. de esta forma definimos los siguientes kernels, que nos ayudaran en la identificacion de Malaria:

$$\begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix}$$

Figure 3. Kernel 1

Con estos kernels, buscamos relieves no usuales en las imágenes que se analizaran, dado que la mayoría de imágenes que se encuentran sanas, no poseen un relieve significativo, es decir, no presentan niveles muy diferentes de gris.

$$\begin{bmatrix} 7 & 14 & 7 \\ 1 & 1 & 1 \\ -7 & -14 & -7 \end{bmatrix}$$

Figure 4. Kernel 2

2.1. ¿cree que las imágenes especificadas presentan un mejor o peor resultado? ¿cuál kernel cree que da un mejor resultado?

Consideramos que el mejor resultado lo da el Kernel 1, ya que como se puede apreciar en la figura 5, encontramos una mejor diferenciación de los niveles de gris en las imágenes 1 y 5 que fueron filtradas con el kernel 1, en comparación con las demás imágenes.




Figure 5. Imágenes de test correlacionadas con los filtros y pre-procesamientos

A pesar de esto, encontramos diferencias significativas

al pre-procesar la imagen, ya que este pre-procesamiento permitio una ejor diferenciacion de los tonos de gris. por lo tanto concluimos que la mejor combinacion sería el kernel 1 con pre-procesamiento de la imagen.

2.2. ¿Por qué cree que el Template Matching funciona para clasificación?

Dado que el template es escogido por una persona, es decir, de manera consciente, es mas facil comparar lo que se predijo contra los valores de dicho template. en nuestro caso, sacamos los valores maximo de cada imagen correlacionada y lo comparamos con el de la imagen de train correspondiente, previamente correlacionada. al realizar la razon entre el maximo de la correlacion de la imagen de train correspondiente a la imagen de test, encontramos la respuesta al kernel. como se puede apreciar en la figura 6, la unica respuesta inesperada fue la de la imagen 4, que en realidad era una imagen de infeccion con malaria, sin embargo, al compararla con el template correspondiente, estos no se asemejaron y por lo tanto se descarto que tuviera malaria.

Imagen	Kernel	Preprocesamiento	Respuesta al Kernel	Predicción
1	1	Si	0.74	Infectado
2	2	Si	0.73	No infectado
3	1	Si	1	No infectado
4	2	No	0.13	No infectado
5	1	Si	0.84	Infectado
6	2	Si	0.82	Infectado
7	1	No	0.98	No infectado
8	2	No	1	Infectado
9	2	Si	1	No infectado
10	1	Si	1	No infectado

Figure 6. Tabla de las imágenes de test y sus clasificaciones según la metodología Template Matching

2.3. ¿Qué limitaciones cree que tiene este método para otro tipo de bases de datos o tareas?

Bases de datos muy grandes donde se requieren varios tipos de kernels y varios tipos de pre procesamiento de imagen para detectar los parametros deseados, pueden representar un problema, pues pueden llegar a existir gran cantidad de templates para comparar. esto supondria un problema en recursos computacionales y tiempo. ademas de estos, dichos templates pueden tener sesgos por parte de los investigadores y por lo tanto no describirian bien que es un resultado positivo y cuando es un falso positivo o falso negativo.

References

- [1] Yanhui Guo Amira S. Ashour. Gaussian noise. *Science Direct*.
- [2] Charles Boncelet. Pepper noise. *Science Direct*.
- [3] Utkarsh Sinha. Generating uniform noise. *AI Shack*.

Realizado en L^AT_EX